(a) 阶段 I：联合动作示范与去噪预训练

示范教师
冻结运动策略＋局部SINR评分

→

联合示范数据
$(o_i, z_i^*, \text{mask}_i)$

→

加噪 → 条件去噪预训练
联合训练集合编码器与去噪器

→

初始化在线 Actor
参数 $\Theta = (\phi, \psi, \theta)$

预训练参数初始化；示范数据不混入PPO概率比

(b) 分布执行：on-policy采集

本机局部观察
固定特征＋历史＋变长感知UE集合
可服务mask：$\mathcal{F}_i^t \subseteq \mathcal{D}_i^t$

o_i^{t+1}

环境与采集器
① t时刻Top-K提议
② UAV / UE运动
③ t+1门控与UE选择

共享集合条件化 Diffusion Actor

UE集合编码＋上下文融合＋有效坐标mask

$z_i^{(L)}$ → $z_i^{(L-1)}$ → … → $z_i^{(0)}$

逐UAV采样：2维运动＋$|\mathcal{F}_i^t|$个评分latent

a_i^t

联合动作映射
运动：圆盘映射
UE评分：Sigmoid

(c) 集中训练：时间因子 Critic ＋ PPO

交互轨迹＋采样器保存的去噪链

本轮 Rollout Buffer（无离策略回放池）
o_t, s_t, r_t, d_t, mask, $\{z^{(L)}, \ldots, z^{(0)}\}$
采样时的 $\log p_{\Theta_{old}}$ 与旧累计价值

s_t, s_{t+1}

时间因子 Critic
$V_\omega(s_t) = H_t \hat{m}_\omega(s_t)$
$H_t = (1-\gamma^{T-t})/(1-\gamma)$
输入全局状态；输出累计价值

V值

r_t, d_t

团队 GAE 与回报目标
$\delta_t = r_t + \gamma(1-d_t)V_{t+1} - V_t$
$\hat{A}_t$ ； $\hat{R}_t = \hat{A}_t + V_{old}(s_t)$
真终止不bootstrap

累计价值目标 $\hat{R}_t$

团队优势 $\hat{A}_t$

同链评估

Critic价值回归
累计价值空间 Huber＋Value Clip
平均奖励PopArt / 独立优化器

去噪转移 PPO Clip
逐UAV、逐随机去噪步计算概率比
在同一条旧去噪链上重算概率

策略梯度更新集合编码器、上下文与去噪器；不经过Top-K反向传播

拟实施方案｜容量10，$r_t = \rho_t + 0.1\tau_t$｜实线：数据 / 价值；虚线：参数初始化或更新